

DADS6005 MIDTERM REALTIME

Data streaming and Realtime analytics System Requirement a. Data source 3 sources

a. Data source 3 sources [1]

i. Source 1 : PageView (stream datagen) (topic1)

PageView เป็นแหล่งข้อมูลที่สร้างข้อมูลจำลองเกี่ยวกับการดูหน้าเว็บของผู้ใช้งาน โดยใช้ Kafka Connect Data Generator เพื่อสร้างข้อมูลในรูปแบบ JSON (ไม่มีการกำหนด schema) และส่งไปยัง Kafka topic 1\_pageviews ข้อมูลนี้ประกอบด้วยเวลาในการดู (viewtime), รหัสผู้ใช้งาน (userid), และรหัสหน้าเว็บ (pageid) ซึ่งถูกสร้างขึ้นแบบสุ่มในช่วงเวลาที่กำหนด (random interval) จากนั้นใช้ Kafka Stream ชื่อ pageviews\_stream เพื่อดึงข้อมูลเข้าสู่ระบบสำหรับการประมวลผลแบบเรียลไทม์ ข้อมูลนี้มีความสำคัญต่อการวิเคราะห์พฤติกรรมผู้ใช้ เช่น การติดตามการใช้งานเว็บไซต์ และการปรับปรุงกลยุทธ์การตลาด ตัวอย่างข้อมูลที่ได้ ได้แก่ {"viewtime": 691001, "userid": "User\_6", "pageid": "Page\_22"} ซึ่งสามารถนำไปใช้งานในการสร้างรายงานหรือวิเคราะห์เชิงลึกได้

<pre>{   "name": "datagen-pageviews",   "connector.class":     "io.confluent.kafka.connect.datagen.DatagenConnector",   "key.converter":     "org.apache.kafka.connect.storage.StringConverter",   "value.converter":     "org.apache.kafka.connect.json.JsonConverter",   "value.converter.schemas.enable": "false",   "kafka.topic": "1_pageviews",   "max.interval": "1000",   "quickstart": "pageviews",   "interval.type": "random",   "interval.range.min": "1",   "interval.range.max": "100"</pre>	<pre>CREATE STREAM pageviews_stream (   viewtime BIGINT,   userid VARCHAR,   pageid VARCHAR ) WITH (KAFKA_TOPIC='1_pageviews', VALUE_FORMAT='JSON');</pre>	<pre>{   "viewtime": 691001,   "userid": "User_6",   "pageid": "Page_22" }</pre>
--	--	--

ii. Source 2 : Users\_ (stream datagen) (topic2)

Users เป็นแหล่งข้อมูลจำลองเกี่ยวกับผู้ใช้งานที่สร้างขึ้นโดย Kafka Connect Data Generator ข้อมูลนี้ส่งไปยัง Kafka topic 2\_users ในรูปแบบ JSON (ไม่มีการกำหนด schema) ประกอบด้วยเวลาลงทะเบียน (registertime), รหัสผู้ใช้งาน (userid), ภูมิภาค (regionid), และเพศ (gender) โดยมีการสร้างข้อมูลในช่วงเวลาสุ่ม (random interval) จากนั้นสร้าง Kafka Table ชื่อ users\_tb ซึ่งกำหนด userid เป็น Primary Key เพื่อจัดเก็บข้อมูลดังกล่าว ข้อมูลนี้มีความสำคัญต่อการวิเคราะห์พฤติกรรมผู้ใช้งานและเชื่อมโยงข้อมูลในระบบ เช่น การติดตามกลุ่มผู้ใช้งานในแต่ละภูมิภาค ตัวอย่างข้อมูล ได้แก่ {"registertime": 1491293306724, "userid": "User\_7", "regionid": "Region\_8", "gender": "MALE"} ซึ่งสามารถนำไปใช้ในการวิเคราะห์ข้อมูลเชิงลึกและการตลาดแบบเฉพาะกลุ่ม.

<pre>{   "name": "datagen-users",   "connector.class":     "io.confluent.kafka.connect.datagen.DatagenConnector",   "key.converter":     "org.apache.kafka.connect.storage.StringConverter",   "value.converter":     "org.apache.kafka.connect.json.JsonConverter",   "value.converter.schemas.enable": "false",   "kafka.topic": "2_users",   "max.interval": "1000",   "quickstart": "users",   "interval.type": "random",   "interval.range.min": "1",   "interval.range.max": "100" }</pre>	<pre>CREATE TABLE users_tb (   registertime BIGINT,   userid VARCHAR PRIMARY KEY,   regionid VARCHAR,   gender VARCHAR ) WITH (KAFKA_TOPIC='2_users',       VALUE_FORMAT='JSON');</pre>	<pre>{   "registertime":     1491293306724,   "userid": "User_7",   "regionid": "Region_8",   "gender": "MALE" }</pre>
--	---	--

.iii. Source 3 : Your design (relational database) (topic3)

Orders เป็นแหล่งข้อมูลที่จัดเก็บคำสั่งซื้อของผู้ใช้งานในรูปแบบ relational database โดยใช้ Python script สร้างข้อมูลจำลอง เช่น รหัสคำสั่งซื้อ (orderid), รหัสผู้ใช้งาน (userid), ประเภทสินค้า (product\_type), จำนวน (quantity), และสถานะ (status) จากนั้นส่งข้อมูลในรูปแบบ JSON ไปยัง Kafka topic 3\_orders ข้อมูลเหล่านี้ถูกนำเข้า Kafka Stream ชื่อ orders\_stream เพื่อประมวลผลแบบเรียลไทม์ ข้อมูลคำสั่งซื้อที่มีความสำคัญต่อการติดตามการขายสินค้า การประเมินยอดขาย และการปรับปรุงกระบวนการจัดส่ง ตัวอย่างข้อมูลที่สร้างขึ้น ได้แก่ {"ORDERID": "4e383b6b-3f38-45ad-baec-c100b17a4323", "USERID": "User\_7", "PRODUCT\_TYPE": "Tablet", "UNIT\_PRICE": 318.12, "QUANTITY": 3, "TOTAL\_PRICE": 954.36, "STATE": "Nebraska", "STATUS": "Shipped"} ซึ่งช่วยสนับสนุนการวิเคราะห์ยอดขายและการจัดการคำสั่งซื้อในระบบ.

<pre>CREATE STREAM orders_stream (   ORDERID STRING,   USERID STRING,   ORDER_TIMESTAMP STRING,   PRODUCT_TYPE STRING,   UNIT_PRICE DOUBLE,   QUANTITY INT,   TOTAL_PRICE DOUBLE,   STATE STRING,   STATUS STRING ) WITH (   KAFKA_TOPIC='3_orders',   VALUE_FORMAT='JSON' );</pre>	<pre>{   "ORDERID": "4e383b6b-3f38-45ad-baec-c100b17a4323",   "USERID": "User_7",   "ORDER_TIMESTAMP": "2024-11-16T08:33:16.098003",   "PRODUCT_TYPE": "Tablet",   "UNIT_PRICE": 318.12,   "QUANTITY": 3,   "TOTAL_PRICE": 954.36,   "STATE": "Nebraska",   "STATUS": "Shipped" }</pre>
---	---

## b. Kafka system [2]

### i. 5 partitions

Kafka ใช้ partitions ในการแบ่งข้อมูลภายในแต่ละ topic เพื่อเพิ่มประสิทธิภาพในการจัดการและกระจายข้อมูลไปยัง brokers หลายตัว ในระบบนี้ topic แต่ละอันถูกแบ่งออกเป็น 5 partitions ซึ่งช่วยให้รองรับการประมวลผลข้อมูลแบบขนาน (parallel processing) ได้ดีขึ้นและเพิ่มประสิทธิภาพทั้งในด้านการเขียนและการอ่านข้อมูล นอกจากนี้ การใช้ partitions ยังช่วยเพิ่มความสามารถในการขยายระบบ (scalability) และรองรับการใช้งานที่มีข้อมูลจำนวนมาก โดยข้อมูลจะถูกกระจายอย่างสมดุลไปยัง brokers ต่างๆ เพื่อให้ระบบทำงานได้อย่างราบรื่น.

### ii. 3 brokers

ในการสร้างระบบ Kafka เราจะสร้าง 3 brokers หมายถึงมี 3 servers ที่ทำหน้าที่ในการจัดการและจัดเก็บข้อมูล โดย brokers จะรับข้อมูลจาก producer และส่งข้อมูลไปยัง consumer การใช้หลาย brokers ช่วยเพิ่มความทนทาน (fault tolerance) ของระบบ เนื่องจากหาก broker ตัวใดตัวหนึ่งล้มเหลว ข้อมูลยังคงสามารถเข้าถึงได้จาก brokers อื่นๆ ที่มีข้อมูลสำรอง (replica) อยู่ ทำให้ระบบมีความเสถียรและสามารถดำเนินการต่อไปได้โดยไม่กระทบต่อการทำงานของระบบ ในที่นี้ ระบบใช้ broker:29092, broker1:29095, และ broker2:29098 เพื่อจัดการข้อมูลและรองรับการกระจายข้อมูลระหว่าง servers.

### iii. 8 topics

ในการสร้าง 8 topics หมายถึงมีการตั้งค่าไว้ทั้งหมด 8 topic ที่ใช้ในการแยกประเภทข้อมูล โดยแต่ละ topic จะรับข้อมูลจาก producers และส่งข้อมูลไปยัง consumers เพื่อการประมวลผลหรือการใช้งานต่อไป การใช้หลายๆ topic ช่วยให้สามารถจัดการและแยกประเภทข้อมูลที่แตกต่างกันได้อย่างมีประสิทธิภาพ เช่น หนึ่ง topic อาจใช้สำหรับการบันทึกข้อมูลการสั่งซื้อ (orders), อีก topic อาจใช้สำหรับการบันทึกข้อมูลผู้ใช้ (users), ซึ่งทำให้สามารถควบคุมข้อมูลแต่ละประเภทได้อย่างเป็นระเบียบและสามารถเข้าถึงได้ง่ายขึ้นในระบบ

### iv. Schema Register

Schema Registry เป็นเครื่องมือที่ช่วยในการจัดการ schema ของข้อมูลที่ถูกส่งไปยัง Kafka topics เช่น Avro, JSON, หรือ Protobuf โดยทำหน้าที่ตรวจสอบและรับรองว่า ข้อมูลที่ถูกส่งไปยัง Kafka มีรูปแบบที่ถูกต้องและสอดคล้องกับ schema ที่กำหนดไว้ ช่วยให้มั่นใจได้ว่าข้อมูลมีความสมบูรณ์และสามารถตรวจสอบได้เมื่อมีการส่งข้อมูลระหว่าง producers และ consumers ผ่าน Kafka โดยการใช้ Schema Registry ยังช่วยในการป้องกันปัญหาการเข้ากันไม่ได้ระหว่างรูปแบบข้อมูลที่ต่างกัน เช่น เมื่อข้อมูลถูกส่งในรูปแบบ Avro หรือ JSON และช่วยให้ง่ายต่อการบำรุงรักษาและการเปลี่ยนแปลง schema ในระบบได้อย่างราบรื่น.

## v. Kafka connect

Kafka Connect เป็นเครื่องมือที่ช่วยเชื่อมต่อ Kafka กับแหล่งข้อมูลภายนอก เช่น ฐานข้อมูล, ระบบการจัดเก็บข้อมูล, หรือแอปพลิเคชันอื่นๆ โดยใช้ connectors ที่ช่วยในการดึงข้อมูลจากแหล่งภายนอกเข้าสู่ Kafka หรือส่งข้อมูลจาก Kafka ไปยังระบบภายนอก การใช้ Kafka Connect ช่วยให้การทำงานกับข้อมูลภายนอกเป็นไปอย่างสะดวกและรวดเร็ว โดยไม่จำเป็นต้องเขียนโค้ด เนื่องจาก connectors จะทำการเชื่อมต่อและถ่ายโอนข้อมูลอย่างอัตโนมัติ โดยในกรณีนี้เราใช้ Data Generator เพื่อสร้างข้อมูลจำลองเกี่ยวกับ pageviews และ users ซึ่งช่วยให้สามารถสร้างข้อมูลทดสอบได้ง่ายและรวดเร็วโดยไม่ต้องใช้ข้อมูลจริง.

## c. ksqlDB operation [3]

## i. Clean or transform data (topic4)

เราได้ทำการ transforming ข้อมูลจากสองแหล่งข้อมูล (sources) คือ PAGEVIEWS\_STREAM และ users\_tb เราจะทำแปลงข้อมูลที่มีอยู่ให้มีรูปแบบที่เข้าใจได้ง่ายและถูกต้องมากขึ้น:

1. PAGEVIEWS\_STREAM: ข้อมูลที่เกี่ยวข้องกับ viewtime หรือเวลาในการดูหน้าเว็บจะถูกแปลงจากหน่วยมิลลิวินาทีเป็นหน่วยนาฬิกา (โดยการหารด้วย 6000) เพื่อให้สามารถเข้าใจได้ง่ายขึ้น เช่น การแปลงข้อมูล VIEWTIME = 691001 มิลลิวินาที จะกลายเป็น VIEWTIME\_FORMATTED = 22 นาที ข้อมูลที่ถูกแปลงนี้จะถูกส่งไปยัง Kafka topic 4\_cleaned โดยใช้คำสั่ง CREATE STREAM.
2. users\_tb: ข้อมูลที่เกี่ยวข้องกับ REGISTERTIME หรือเวลาลงทะเบียนผู้ใช้งานจะถูกแปลงจากมิลลิวินาทีเป็นรูปแบบเวลาที่เข้าใจได้ง่าย (เช่น yyyy-MM-dd HH:mm)

) ด้วยการใช้ฟังก์ชัน TIMESTAMPTOSTRING ซึ่งจะทำให้เวลาที่มีรูปแบบเช่น 1970-01-18 17:30:02 สามารถอ่านและตีความได้ง่ายขึ้น ข้อมูลนี้จะถูกส่งไปยัง Kafka topic 4\_cleaned ด้วยคำสั่ง CREATE TABLE.

การแปลงข้อมูลเหล่านี้ช่วยให้ข้อมูลมีความถูกต้องและเข้าใจง่ายขึ้น ทำให้การประมวลผลข้อมูลในภายหลัง เช่น การวิเคราะห์หรือการใช้งานในระบบอื่น ๆ เป็นไปได้อย่างมีประสิทธิภาพและมีความแม่นยำมากขึ้น.

<pre>CREATE STREAM PAGEVIEWS_CLEAN WITH (KAFKA_TOPIC = '4_cleaned', VALUE_FORMAT = 'JSON') AS SELECT   USERID,   PAGEID,   VIEWTIME/6000 AS VIEWTIME_FORMATTED FROM PAGEVIEWS_STREAM;</pre>	<pre>{   "USERID": "User_2",   "PAGEID": "Page_97",   "VIEWTIME_FORMATTED": 22 }</pre>
<pre>CREATE TABLE USERS_CLEAN WITH (KAFKA_TOPIC = '4_cleaned', VALUE_FORMAT = 'JSON') AS SELECT   USERID,   REGIONID,   GENDER,   TIMESTAMPTOSTRING(REGISTERTIME / 1000, 'yyyy-MM-dd HH:mm:ss', 'Asia/Bangkok') AS REGISTERTIME_FORMATTED FROM users_tb;</pre>	<pre>{   "USERID": "User_6",   "REGIONID": "Region_1",   "GENDER": "OTHER",   "REGISTERTIME_FORMATTED": "1970-01-18 17:30:02" }</pre>

## ii. Aggregation (join + group by) (topic5)

การ aggregation นี้ เราจะทำการรวบรวมข้อมูลคำสั่งซื้อจาก ORDERS\_STREAM และข้อมูลผู้ใช้จาก USERS\_CLEAN โดยการใช้ JOIN ข้อมูลทั้งสองแหล่ง และทำการ GROUP BY ตามประเภทสินค้าที่สั่งซื้อ (PRODUCT\_TYPE). การ JOIN จะทำให้เราสามารถเชื่อมโยงข้อมูลคำสั่งซื้อกับข้อมูลของผู้ใช้งานผ่าน USERID เพื่อให้ได้ข้อมูลที่ครบถ้วนมากขึ้น.

หลังจากนั้น เราจะคำนวณข้อมูลต่าง ๆ ที่เกี่ยวข้อง เช่น:

- total\_orders: จำนวนคำสั่งซื้อทั้งหมดในแต่ละประเภทสินค้า
- total\_sales: ยอดขายรวมจากคำสั่งซื้อทั้งหมด
- avg\_sales\_per\_order: ยอดขายเฉลี่ยต่อคำสั่งซื้อ

ข้อมูลที่ได้จากการคำนวณนี้จะถูกส่งไปยัง Kafka topic 5\_aggregated ซึ่งจะช่วยให้ข้อมูลที่รวบรวมและประมวลผลแล้วสามารถนำไปใช้งานหรือวิเคราะห์ได้ต่อไป เช่น การสร้างรายงาน หรือการใช้ข้อมูลในแอปพลิเคชันที่เกี่ยวข้อง

<pre>CREATE TABLE 5_sales_by_product WITH (KAFKA_TOPIC = '5_aggregated') AS SELECT o.PRODUCT_TYPE, COUNT(o.ORDERID) AS total_orders, SUM(o.TOTAL_PRICE) AS total_sales, SUM(o.TOTAL_PRICE) / COUNT(o.ORDERID) AS avg_sales_per_order FROM ORDERS_STREAM o LEFT JOIN USERS_CLEAN u ON o.USERID = u.USERID GROUP BY o.PRODUCT_TYPE;</pre>	<pre>{ "PRODUCT_TYPE": "Keyboard", "TOTAL_ORDERS": 187, "TOTAL_SALES": 49598.9500000000026, "AVG_SALES_PER_ORDER": 265.23502673796804 }</pre>
---	---

### iii. Windows

#### 1. Tumbling (topic6)

การ Tumbling Window นี้เราจะใช้ฟังก์ชัน TUMBLING (SIZE 1 HOUR) เพื่อคำนวณจำนวนการดูหน้าเว็บ (pageviews) ของผู้ใช้แต่ละคนในช่วงเวลาที่เป็น 1 ชั่วโมง ซึ่งจะไม่ทับซ้อนกัน โดยการใช้ Tumbling Window จะช่วยแบ่งข้อมูลออกเป็นช่วงเวลาที่ชัดเจน เช่น ช่วงเวลา 1 ชั่วโมง ซึ่งข้อมูลแต่ละช่วงจะถูกคำนวณแยกจากกันและไม่ทับซ้อนกัน

การคำนวณจะทำการ COUNT จำนวนการดูหน้าเว็บ (pageviews) ของผู้ใช้ (USERID) ในแต่ละช่วงเวลา (window) และผลลัพธ์ที่ได้จะประกอบด้วย:

- USERID: รหัสผู้ใช้ที่ทำการดูหน้าเว็บ
- PAGEVIEWS\_COUNT: จำนวนครั้งที่ผู้ใช้งานดูหน้าเว็บในช่วงเวลา 1 ชั่วโมง
- WINDOWSTART และ WINDOWEND: เวลาเริ่มต้นและสิ้นสุดของช่วงเวลา 1 ชั่วโมงที่ใช้ในการคำนวณ

ข้อมูลที่ได้จะถูกส่งไปยัง Kafka topic 6\_tumbling ซึ่งสามารถนำไปใช้งานต่อในระบบการประมวลผลข้อมูลแบบเรียลไทม์ หรือใช้ในการวิเคราะห์พฤติกรรมของผู้ใช้ในช่วงเวลาต่าง ๆ.

<pre>CREATE TABLE 6_pageviews_per_user WITH (KAFKA_TOPIC='6_tumbling') AS SELECT pv.USERID, COUNT(*) AS PAGEVIEWS_COUNT FROM PAGEVIEWS_CLEAN pv WINDOW TUMBLING (SIZE 1 HOUR) -- 1-hour window GROUP BY pv.USERID EMIT CHANGES;</pre>	<pre>{ "USERID": "User_7", "WINDOWSTART": 1731740400000, "WINDOWEND": 1731744000000, "PAGEVIEWS_COUNT": 153 }</pre>
---	---

## 2. Hopping (topic7)

การ Hopping Window นี้เราจะใช้ HOPPING (SIZE 1 HOUR, ADVANCE BY 30 MINUTES) เพื่อคำนวณจำนวนคำสั่งซื้อและยอดขายรวมของผู้ใช้แต่ละคนในช่วงเวลา 1 ชั่วโมง โดยการเลื่อนช่วงเวลา (hop) ทุก ๆ 30 นาที. การใช้ Hopping Window ช่วยให้สามารถคำนวณข้อมูลได้ในหลาย ๆ ช่วงเวลา โดยที่ทุก ๆ 30 นาทีจะมีการเลื่อนช่วงเวลาใหม่เข้ามา ซึ่งทำให้สามารถคำนวณข้อมูลใหม่ในแต่ละช่วงเวลาได้อย่างต่อเนื่องและซ้ำซ้อนกัน.

ผลลัพธ์ที่ได้จากการคำนวณจะประกอบด้วย:

- USERID: รหัสผู้ใช้ที่ทำการสั่งซื้อ
- ORDER\_COUNT: จำนวนคำสั่งซื้อของผู้ใช้ในช่วงเวลานั้น
- TOTAL\_SALES: ยอดขายรวมจากคำสั่งซื้อในช่วงเวลานั้น
- WINDOWSTART และ WINDOWEND: เวลาเริ่มต้นและสิ้นสุดของช่วงเวลา (window) ที่ใช้ในการคำนวณข้อมูลที่ได้จะถูกส่งไปยัง Kafka topic 7\_hopping ซึ่งสามารถใช้ในการวิเคราะห์และติดตามพฤติกรรมคำสั่งซื้อของผู้ใช้ในช่วงเวลาต่าง ๆ เช่น การวิเคราะห์ยอดขายในช่วงเวลาที่มีการเปลี่ยนแปลงอย่างรวดเร็ว.

<pre>CREATE TABLE 7_total_orders_hopping WITH (KAFKA_TOPIC='7_hopping') AS SELECT   o.USERID,   COUNT(*) AS ORDER_COUNT,   SUM(o.TOTAL_PRICE) AS TOTAL_SALES FROM orders_stream o WINDOW HOPPING (SIZE 1 HOUR, ADVANCE BY 30 MINUTES) -- 1-hour window, hops every 30 minutes GROUP BY o.USERID EMIT CHANGES;</pre>	<pre>{   "USERID": "User_7",   "WINDOWSTART": 1731740400000,   "WINDOWEND": 1731744000000,   "PAGEVIEWS_COUNT": 153 }</pre>
---	---

## 3. Session (topic8)

การ Session Window นี้เราจะใช้ Session Window เพื่อติดตามและคำนวณจำนวนคำสั่งซื้อและยอดรวมคำสั่งซื้อของผู้ใช้แต่ละคนในช่วงเวลาที่กำหนด 10 นาที ซึ่งระบบจะพิจารณาว่าเซสชันสิ้นสุดเมื่อไม่มีการกระทำจากผู้ใช้ภายในช่วงเวลา 10 นาที. เมื่อไม่มีคำสั่งซื้อใหม่เกิดขึ้นในช่วงเวลานั้น เซสชันจะถูกปิดและเริ่มเซสชันใหม่ทันที.

ผลลัพธ์ที่ได้จะประกอบด้วย:

- ORDER\_COUNT: จำนวนคำสั่งซื้อที่ผู้ใช้ทำในเซสชันนั้น
- TOTAL\_ORDER\_VALUE: ยอดรวมของคำสั่งซื้อที่เกิดขึ้นในเซสชัน
- WINDOWSTART และ WINDOWEND: เวลาที่เริ่มต้นและสิ้นสุดของเซสชันนั้น



ข้อมูลที่ได้จะถูกส่งไปยัง Kafka topic 8\_session, ซึ่งสามารถนำไปใช้ในการวิเคราะห์พฤติกรรมการสั่งซื้อของผู้ใช้ที่มี การกระทำหรือกิจกรรมอย่างต่อเนื่องในช่วงเวลาที่กำหนด และช่วยในการติดตามความสัมพันธ์ระหว่างผู้ใช้และการ สั่งซื้อในช่วงเวลานั้น ๆ.

<pre>CREATE TABLE 8_orders_session_table WITH (KAFKA_TOPIC='8_session') AS SELECT   USERID,   COUNT(*) AS ORDER_COUNT,   SUM(TOTAL_PRICE) AS TOTAL_ORDER_VALUE FROM orders_stream WINDOW SESSION (10 MINUTES) GROUP BY USERID EMIT CHANGES;</pre>	<pre>{   "USERID": "User_5",   "WINDOWSTART": 1731745993095,   "WINDOWEND": 1731747620802,   "ORDER_COUNT": 180,   "TOTAL_ORDER_VALUE": 278670.22 }</pre>
---	---

#### iv. Testing the correctness [4]

สำหรับการทำ testing correctness ในระบบที่ใช้ ksqldb, การทดสอบจะมุ่งเน้นที่การตรวจสอบความถูกต้องของ การประมวลผลข้อมูลและการทำงานของ streams และ tables ที่ถูกสร้างขึ้นใน ksqldb เพื่อให้แน่ใจว่าข้อมูลที่ได้จากการ คิวรีเป็นไปตามที่คาดหวังและสามารถทำงานได้ตามความต้องการ. โดยในที่นี้เราจะทำการสร้าง input.json, output.json และ statement.sql ในการทดสอบ

การทดสอบความถูกต้องใน ksqldb มุ่งเน้นที่การตรวจสอบการประมวลผลข้อมูลจาก Kafka stream ว่าถูกต้อง หรือไม่ โดยใช้ input.json, output.json, และ statement.sql ดังนี้:

1. input.json: ข้อมูลตัวอย่างที่ส่งไปยัง Kafka topic เช่น USER\_ID, PAGE\_URL, และ TIMESTAMP.
2. statement.sql: คำสั่ง SQL สำหรับสร้าง stream และคิวรีข้อมูลจาก Kafka topic.
3. output.json: ผลลัพธ์ที่คาดหวังจากการคิวรีข้อมูลใน ksqldb.

โดยข้อมูลใน input.json จะถูกส่งไป Kafka, จากนั้นจะใช้คำสั่งใน statement.sql เพื่อดึงข้อมูลและเปรียบเทียบกับ output.json เพื่อทดสอบความถูกต้องในการประมวลผลข้อมูล.

```
CREATE STREAM pageviews (
  USER_ID STRING,
  PAGE_URL STRING,
  TIMESTAMP TIMESTAMP
) WITH (
  KAFKA_TOPIC='datagen-pageviews',
  VALUE_FORMAT='JSON'
);

SELECT USER_ID, PAGE_URL, TIMESTAMP
FROM pageviews
LIMIT 10; -- LIMIT to check a small
batch of records
```

```
@4f4bb7ad2965:~$
Get:4 https://download.docker.com/linux/ubuntu jammy InRelease [48.8 kB]
Get:5 http://ap-southeast-1.ec2.archive.ubuntu.com/ubuntu jammy-updates/main amd64 Packages [2151 kB]
Get:6 http://ap-southeast-1.ec2.archive.ubuntu.com/ubuntu jammy-updates/universe amd64 Packages [1135 kB]
Get:7 http://security.ubuntu.com/ubuntu jammy-security InRelease [129 kB]
Fetched 3718 kB in 1s (2593 kB/s)
Reading package lists... Done
ubuntu@ip-172-31-44-86:~$ sudo apt-get install confluent-cli
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
E: Unable to locate package confluent-cli
ubuntu@ip-172-31-44-86:~$ ksql --version
Command 'ksql' not found, did you mean:
command 'tsql' from deb freetds-bin (1.3.6-1)
command 'osql' from deb freetds-bin (1.3.6-1)
command 'asql' from deb asql (1.6-1.1)
command 'sql' from deb parallel (20210822+ds-2)
command 'psql' from deb postgresql-client-common (238)
command 'isql' from deb unixodbc (2.3.9-Subunt0.1)
Try: sudo apt install <deb name>
ubuntu@ip-172-31-44-86:~$ sudo nano statements.sql
ubuntu@ip-172-31-44-86:~$ docker cp /home/ubuntu/statements.sql 4f4bb7ad2965:/home/appuser/statements.sql
Successfully copied 2.05kB to 4f4bb7ad2965:/home/appuser/statements.sql
ubuntu@ip-172-31-44-86:~$ docker exec -it 4f4bb7ad2965 /bin/bash
[appuser@4f4bb7ad2965 ~]$ ksql-test-runner -s /home/appuser/statements.sql -i /home/appuser/input.json -o /home/appuser/output.json
>>>>Test passed!!
```

#### d. Apache Pinot [5,6]

Apache Pinot เป็นระบบจัดเก็บข้อมูลแบบคิวรีเรียลไทม์ที่ออกแบบมาเพื่อให้สามารถประมวลผลข้อมูลจากแหล่งข้อมูลภายนอก เช่น Kafka และทำการคิวรีข้อมูลแบบเรียลไทม์ได้อย่างมีประสิทธิภาพ เราได้ใช้ Apache Pinot ในการกำหนด schema และสร้าง real-time tables เพื่อจัดการกับข้อมูลที่ถูกนำเข้ามาจาก Kafka ซึ่งจะช่วยให้เราสามารถประมวลผลข้อมูลในเวลาจริงและทำการคิวรีข้อมูลได้ทันที เราได้สร้าง 3 ตารางใน Apache Pinot ซึ่งมาจาก 3 แหล่งข้อมูลหลัก ได้แก่ pageviews, users, และ orders การตั้งค่าระบบนี้ช่วยให้เราสามารถดึงข้อมูลจาก Kafka มาประมวลผลในระบบของ Apache Pinot และใช้ข้อมูลเหล่านั้นเพื่อการวิเคราะห์ที่รวดเร็วและมีประสิทธิภาพในเวลาจริง.

[i]. At least 3 queries

1. คิวรีข้อมูลเฉลี่ยราคาต่อรัฐ : ในการคิวรีข้อมูลเฉลี่ยราคาต่อรัฐ เราจะคำนวณค่าเฉลี่ยของราคาสินค้า (AVG(TOTAL\_PRICE)) แยกตามรัฐ (STATE) จากข้อมูลที่จัดเก็บในตาราง 3\_orders ซึ่งบันทึกการสั่งซื้อทั้งหมด โดยจะใช้การจัดกลุ่มข้อมูลตามรัฐ (GROUP BY STATE) เพื่อคำนวณค่าเฉลี่ยราคาสินค้าของแต่ละรัฐ. ผลลัพธ์ที่ได้จะประกอบด้วย:
  - STATE: รหัสหรือชื่อของรัฐที่มีการสั่งซื้อ
  - avg\_price\_per\_state: ค่าเฉลี่ยของราคาสินค้าต่อรัฐค่าเฉลี่ยของราคาสินค้าต่อรัฐ

ข้อมูลที่ได้จะถูกใช้ในการวิเคราะห์และตัดสินใจทางธุรกิจ เช่น การกำหนดราคาและกลยุทธ์การตลาดที่เหมาะสมตามลักษณะของแต่ละรัฐ โดยผลลัพธ์จะถูกส่งไปยัง dashboard เพื่อแสดงผลต่อไป

SELECT STATE, AVG(TOTAL_PRICE) AS avg_price_per_state FROM 3_orders GROUP BY STATE;	QUERY RESULT	
	Q Search...	
	STATE	avg_price_per_state
	Missouri	1529.3299882766712
	Indiana	1545.0907540173052
	Illinois	1651.6371727748694
	Michigan	1569.0954289215688
	Minnesota	1626.2678299776283
	Kansas	1615.9134561626431
	Ohio	1497.04423030303
	Iowa	1617.5715301204816

2. คิวรีจำนวนการดูหน้าเว็บต่อผู้ใช้และหน้าเว็บ : คำนวณจำนวนการดูหน้าเว็บ (PAGEVIEWS\_COUNT) สำหรับแต่ละผู้ใช้ (USERID) และแต่ละหน้าเว็บ (PAGEID) จากข้อมูลในตาราง 1\_pageviews ซึ่งบันทึกข้อมูลการดูหน้าเว็บทั้งหมด โดยใช้การจัดกลุ่มข้อมูลตาม USERID และ PAGEID. ผลลัพธ์ที่ได้จะประกอบด้วย:

- USERID: รหัสผู้ใช้ที่ดูหน้าเว็บ
- PAGEID: รหัสหรือชื่อของหน้าเว็บที่ถูกดู
- PAGEVIEWS\_COUNT: จำนวนการดูหน้าเว็บของผู้ใช้ในแต่ละหน้าเว็บ

ข้อมูลที่ได้จากคิวรีนี้จะถูกนำไปใช้ในการวิเคราะห์พฤติกรรมการเข้าชมของผู้ใช้ โดยสามารถดูได้ว่าผู้ใช้แต่ละคนดูหน้าเว็บใดบ่อยที่สุด หรือหน้าเว็บไหนที่ได้รับความนิยมมากที่สุด ซึ่งข้อมูลนี้สามารถช่วยในการปรับปรุงประสบการณ์ผู้ใช้บนเว็บไซต์ และสนับสนุนการตัดสินใจทางการตลาด.

SELECT USERID, PAGEID, COUNT(*) AS PAGEVIEWS_COUNT FROM 1_pageviews GROUP BY USERID, PAGEID;	QUERY RESULT		
	Q Search...		
	userid	pageid	PAGEVIEWS_COUNT
	User_8	Page_70	318
	User_7	Page_70	329
	User_9	Page_70	354
	User_2	Page_70	322
	User_1	Page_70	327
	User_4	Page_70	332
	User_3	Page_70	332
	User_9	Page_54	314

3. คำนวณยอดขายรวม (SUM(TOTAL\_PRICE)) ตามประเภทของสินค้า (PRODUCT\_TYPE) จาก table 3\_orders ซึ่งบันทึกข้อมูลการสั่งซื้อ โดยจะแสดงผลยอดขายรวมของแต่ละประเภทสินค้า ผลลัพธ์ที่ได้:
- PRODUCT\_TYPE: ประเภทของสินค้าที่ขาย
  - TOTAL\_SALES: ยอดขายรวมของแต่ละประเภทสินค้า

ข้อมูลที่ได้จากคิวรีนี้จะช่วยในการวิเคราะห์ยอดขายตามประเภทสินค้า เช่น เพื่อตรวจสอบสินค้าที่มียอดขายสูงที่สุด หรือสินค้าที่มีแนวโน้มในการขายดีในช่วงเวลาหนึ่ง ๆ ซึ่งสามารถนำไปใช้ในการวางแผนการจัดสรรสินค้าและการตัดสินใจทางการตลาด.

<pre>SELECT   PRODUCT_TYPE,   SUM(TOTAL_PRICE) AS total_sales FROM 3_orders GROUP BY PRODUCT_TYPE;</pre>	QUERY RESULT		
	Q Search...		
	userid	pageid	PAGEVIEWS_COUNT
	User_8	Page_70	318
	User_7	Page_70	329
	User_9	Page_70	354
	User_2	Page_70	322
	User_1	Page_70	327
	User_4	Page_70	332
	User_3	Page_70	332
	User_9	Page_54	314

e. Dashboard [7] i. At least 4 panels ii. Bonus: Interactive dashboard



ในส่วนของการแสดงผลข้อมูลบน Streamlit: [BoBoShop](#), เราได้พัฒนา dashboard เพื่อให้สามารถดูข้อมูลต่างๆ ที่มีการอัปเดตแบบเรียลไทม์ โดยการเชื่อมต่อกับ Apache Pinot ผ่านพอร์ต 8099 เพื่อดึงข้อมูลจากฐานข้อมูลและแสดงผลได้ดังนี้:

#### 1. ค่าเฉลี่ยราคาต่อประเภทสินค้า (Product Type)

ใช้ `st.metric()` เพื่อแสดงค่าเฉลี่ยราคาของสินค้าแต่ละประเภท โดยคำนวณจากคำสั่ง SQL ที่ดึงข้อมูลจากตาราง `3_orders`. ผลลัพธ์จะถูกแสดงในรูปแบบของ metric สำหรับแต่ละประเภทสินค้า พร้อมทั้งแสดงความแตกต่างระหว่างข้อมูลล่าสุดกับข้อมูลก่อนหน้า เพื่อให้ผู้ใช้สามารถติดตามการเปลี่ยนแปลงของราคาสินค้าได้อย่างชัดเจนและทันที.

#### 2. พฤติกรรมการสั่งซื้อของลูกค้า (Behavior User Data Frame)

ใช้ `st.dataframe()` เพื่อแสดงข้อมูลพฤติกรรมการสั่งซื้อของลูกค้า ซึ่งจะแสดงข้อมูลเช่น จำนวนการสั่งซื้อ, ยอดรวม, และ ค่าเฉลี่ยของการสั่งซื้อ. ฟังก์ชันนี้ช่วยให้เราสามารถดูข้อมูลเชิงลึกในรูปแบบที่มีระเบียบและเข้าใจง่าย โดยการแสดงผลในรูปแบบ dataframe ที่อัปเดตแบบเรียลไทม์.

#### 3. ยอดขายตามประเภทสินค้า

ใช้ `plotly.express.pie` เพื่อแสดง ยอดขายทั้งหมด แยกตามประเภทสินค้าในรูปแบบ Pie Chart. กราฟนี้จะช่วยให้ผู้ใช้เห็นภาพรวมของยอดขายในแต่ละประเภทสินค้าได้อย่างชัดเจนและเข้าใจง่าย โดยการใช้แผนภาพที่เข้าใจได้ง่ายและมีสีสันที่โดดเด่นเพื่อแสดงสัดส่วนยอดขายแต่ละประเภท.

#### 4. จำนวนการดูหน้าเว็บตามผู้ใช้

ข้อมูลจำนวนการดูหน้าเว็บ (`view_count`) จะถูกแสดงตาม PAGEID ของแต่ละหน้าเว็บที่ผู้ใช้เข้าชม โดยสามารถกรองข้อมูลตามหน้าเว็บที่เลือกได้จาก `multiselect`. ฟังก์ชันนี้ช่วยให้ผู้ใช้สามารถเลือกหน้าเว็บที่ต้องการดูข้อมูลและแสดงกราฟที่อัปเดตตามการเลือก, โดยการติดตามข้อมูลการเข้าชมแต่ละหน้าเว็บจะทำให้ง่ายและสะดวก.

#### 5. ยอดการซื้อเฉลี่ยตามรัฐ

ใช้ `plotly.express.choropleth` เพื่อแสดง ยอดการซื้อเฉลี่ย (`avg_purchase_amount`) ตามรัฐต่างๆ ของสหรัฐอเมริกาในรูปแบบ Choropleth map. แผนที่แบ่งสีตามค่าของยอดการซื้อที่แตกต่างกันในแต่ละรัฐ โดยการใช้แผนที่แบบสีที่มีการเน้นให้เห็นความแตกต่างของยอดการซื้อระหว่างรัฐต่างๆ ช่วยให้ผู้ใช้เห็นข้อมูลการซื้อที่แตกต่างกันในแต่ละพื้นที่ได้อย่างชัดเจน.

ฟีเจอร์เสริม:

- Auto-refresh: หน้า dashboard มีการแสดงผลแบบอัปเดตอัตโนมัติทุก 5 วินาทีผ่าน checkbox เพื่อให้ข้อมูลที่แสดงผลมีความทันสมัยและถูกต้องตลอดเวลา.
- การแสดงภาพสินค้า: ด้านท้ายของ dashboard ยังมีการแสดง รูปภาพสินค้า เพื่อเสริมการนำเสนอข้อมูลและทำให้การนำเสนอข้อมูลมีความหลากหลายและน่าสนใจมากขึ้น.

การใช้งาน Streamlit ร่วมกับ Apache Pinot ทำให้สามารถแสดงข้อมูลจาก Kafka แบบเรียลไทม์ได้อย่างมีประสิทธิภาพ โดยสามารถติดตามการเปลี่ยนแปลงและแสดงผลข้อมูลเชิงลึกได้สะดวกผ่าน dashboard ที่ใช้งานง่าย.